啤酒化合物分析与风味预测建模方案

2026 年 MathorCup 大数据竞赛 · 赛道 A 初赛
数据核查与数学模型设计分析稿

本文件定位：整合题面、附件核查结果与三问建模思路。尚未开展正式训练、Top-3 筛选或风格生成实验；所有模型参数均待数据划分后估计。原始题面与附件保持不变。

研究背景与现实目标

啤酒风味受到酯类、醇类、萜类、硫化物及理化环境共同影响。完整人工品评耗时，化合物之间又具有共线性、缺失和尺度混合等特点。本研究拟以化学测量预测感官表现，识别稳定的关联因素，并在限制缺陷恶化的条件下提出候选风格化合物谱。

问题一
化学特征 → 感官画像

→

问题二
关联网络 → 关键因素

→

问题三
风格生成 → 缺陷约束迁移

已与用户确认的分析口径

评分范围 核心 30 项香气／风味指标，加扩展 20 项感官指标。评分卡中的两项乙醛感受缺少对应专业品评标签，单列为证据不足项。

评分尺度 没有额外的原始 0 – 6 评分、标准化参数或官方勘误。以标准化连续值为监督目标，0 – 6 输出仅定义为相对强度等级，不能声称还原原始评分。

建模边界 本轮形成分析方案，暂不修改附件、不编造模型结果、不将候选化合物谱直接解释为可执行酿造配方。

阅读顺序

第 2 页：附件核查；第 3 页：预处理与假设；第 4 页：符号与感官预测；第 5 页：相对分级；第 6 页：关键因素；第 7 页：风格生成；第 8 页：跨风格迁移；第 9 页：验证与适用边界；第 10 页：实施接口和来源。

编制日期：2026-10-23 资料范围：当前文件夹中的题面与附件 版本：分析稿 1.0

02 附件结构与已核实差异

来源	实际结构	建模用途与注意点
1.csv	250 × 234 列	3 列标识＋231 个特征，22 种风格；73 个缺失值。主输入。
2.csv	231 × 231	化合物相关矩阵；重算确认为 Spearman。
3.xlsx	12 张评分卡＋summary	评分卡未填写；汇总页零值由空白公式产生。仅作评分体系与字段参考。
4.csv	250 × 53 列	3 列标识＋50 个标准化感官指标，无缺失。主监督标签。
5.csv	50 × 50	感官指标 Spearman 相关矩阵。关系核对。
6.csv	44 × 50	化学／理化与感官的 Spearman 交叉相关矩阵。
7.csv	250 × 189 列	3 列标识＋186 个数值描述符；其中 3 列完全缺失。辅助验证。
8.xlsx	7 个工作表	包含阈值、名称、70 项校准特征、已有 GBM 解释、价格和空表。

不能直接沿用题面叙述的地方

样本与维度 题面背景写 226 种啤酒，实际主数据为 250 个样本；评分卡实际为 12 张；6.csv 为 44×50；7.csv 为 186 个描述符。以实际文件为准，不据此删减样本。

相关系数 2.csv、5.csv、6.csv 均与样本数据重算的 Spearman 系数一致。2.csv 的 Pearson 重算结果并不一致。

样本主键 beer 编号完整覆盖 1 – 250，且主表间风格标签一致。4.csv、7.csv 的 beer_id 因舍入出现重复，合并时使用 beer。

评分模板 空白输入被公式解释为零，不等于观测到零强度。模板中的乙醛香气、乙醛风味也没有对应的专业品评标签。

来源：[S1] – [S9]。本页结构统计已扣除 CSV 表头；矩阵尺寸已扣除行列名称。

03 数据预处理与基本假设

先统一数据含义，再做模型训练

逐列建立变换字典 记录字段、中文／化学名称、单位、变换方式、校准来源及可信程度。可核验的前 37 项指标满足 log10 变换，包括 pH、酒精度、色度；不能按题面将它们视为原值。

$$x_{ij} = \log_{10}(C_{ij}), C_{ij} > 0 \tag{1}$$

例如 beer=10 的 pH 字段为 0.624797579，对应原值 4.215。前 37 项共 8,452 个有效正值配对的最大 log10 误差约为 2.93×10^{-9}。部分零值采用最小正值的一半替代后取对数，不能把指数逆变换后的下限值当成真实测量。

区分缺失、零与未检出 1.csv 的 NA、校准表中的零值、既有替代下限分别标记。普通缺失可在训练折内插补；未检出值则保留指示变量，并对下限替代规则做敏感性分析。

保留并核对异常 先检查单位和录入一致性，再采用稳健损失或敏感性对照。校准表与主表少量记录不一致，阈值计算前必须固定数据来源，不能混用两套值。

派生指标单独处理 热量值、总酯、酒花香气、总酸、总硫等 5 项综合属性可先不进入基础模型，以避免重复计数；扩展模型再作消融比较。合计 231−5=226 个基础特征仍包含理化参数。

五项基本假设及其边界

假设	作用与局限
测量可比	不同样本测量口径基本一致；批次效应未知，应检查并在可能时分组验证。
映射可学习	化学特征对感官具有统计预测信息；结论限于数据覆盖的浓度与风格范围。
缺失可辅助估计	普通缺失与未检出分别处理；不能保证非随机缺失已完全校正。
风格共享低维结构	不同风格共享变化模式，均值与协方差不同；用于缓解稀有风格小样本。
缺陷逐项不恶化	限制每项缺陷，不能用其他缺陷的改善抵消某项恶化。

04 符号定义与感官预测模型

符号	定义
i，j，d	样本 i=1,⋯,250；特征 j=1,⋯,p；感官维度 d=1,⋯,50。
c_i	第 i 个样本的风格，22 类；各类样本数不均衡。
u_i，y_{id}	完成训练折内预处理的特征向量；附件提供的标准化感官分数。
a，B	感官预测截距与回归系数；B 的每列对应一个感官维度。
$C_j(u)$，T_j	经核实逆变换得到的原始浓度／理化值；同单位的感官阈值。
λ_1，λ_2，λ_G	稀疏、平方与网络正则化参数，由训练内部验证选取。

问题一：以标准化感官值为直接预测目标

$$\hat{y}_{id} = a_d + u_i^{T} b_d \tag{2}$$

$$\min_{a,B} (1/nD) \sum_{i=1\ldots n} \sum_{d=1\ldots D} H_\delta(y_{id} - a_d - u_i^{T} b_d) + \lambda_1 ||B||_1 + \lambda_2 ||B||_F^{2} \tag{3}$$

Hδ 为 Huber 损失，兼顾小残差拟合与大残差稳健性；L1 项促使系数稀疏，平方项缓解共线性。这里的范数均作用于回归系数，不惩罚截距。

$$H_\delta(e) = \{ e^2/2, |e| \le \delta; \ \delta|e| - \delta^2/2, |e| > \delta \} \tag{4}$$

求解与比较

在给定正则化参数下求解凸优化问题。使用重复三折外层验证评估误差，内层验证选择参数。以偏最小二乘或岭回归为基线，梯度提升树为非线性比较模型；只有验证结果支持时才增加复杂性。

停止条件采用求解器收敛容差及目标函数变化阈值，并记录迭代次数。该线性骨架可解释性较强，但不能充分刻画协同、掩蔽和饱和效应。

05 0–6 相对分级与尺度不确定性

关键限制：现有附件缺少原始评分和标准化参数。连续监督模型可训练，但其输出不能唯一换算回人工评分卡的绝对 0–6 分。以下为用户已同意的相对分级方案。

为什么不能直接恢复原评分

$$y = (s - \mu)/\sigma \Rightarrow s = \mu + \sigma y \tag{5}$$

即使采用最简单的线性标准化解释，缺少 μ、σ 时也存在多组可行的原始尺度。实际标签未必仅经过这一步变换，因此不能将观测最小值、最大值硬映射为 0 和 6，并称之为原始评分。

训练分位数定义相对强度等级

$$t_{dk} = Q_{d,train}(k/7), k = 1,\ldots,6 \tag{6}$$

$$\hat{g}_{id} = \sum_{k=1\ldots6} 1(\hat{y}_{id} > t_{dk}), \hat{g}_{id} \in \{0,1,\ldots,6\} \tag{7}$$

Qd,train 是训练集第 d 个标签的经验分位数。分界点只从训练数据估计，应用到验证或新样本时固定。等级 0 表示相对低强度，并不自动代表“未检出／完全不存在”；等级 6 表示相对高强度，也不等同于评分卡的“压倒性强烈”。

若低强度值大量重复，分界点可能相同，部分等级可以不出现。保留这种现象，不能通过微扰标签强行制造七档。分位数等级跨维度可比较相对位置，不能比较绝对感官强度。

输出与证据等级

输出	解释与证据
连续感官预测	50 项：核心 30 项＋扩展 20 项。使用附件标准化标签评价，属于主要可验证输出。
相对 0–6 等级	由训练分位数定义。应附连续预测及不确定区间，并清楚标注“相对强度”。
两项乙醛感受	缺少对应专业标签。单列证据不足，暂不输出有监督评分，也不视为零。
不确定性	利用重采样拟合波动及验证残差评估区间；若报告名义覆盖率，还需单独校准与检验。

连续预测评价采用逐维 MAE、RMSE、Spearman 相关，并报告宏平均与风格分组误差。没有原始等级真值时，不宣称已验证原始 0–6 评分准确率。

06 问题二：化合物网络与稳定 Top-3

构建带符号的相关网络

以单项化合物为节点，按 Spearman 相关构建加权边。理化参数和派生综合指标可进入辅助网络，但最终“关键化合物”应在明确的化合物候选集合中选择。

$$W_{jk} = |\rho_{jk}| \cdot 1(|\rho_{jk}| \geq \tau), W_{jj} = 0 \tag{8}$$

ϱjk 是相关系数，τ 是稀疏化阈值。题目所称“共表达图”在本数据中应解释为化合物共变网络，不具有基因表达或因果作用的含义。

网络约束的感官预测

$$L_{total} = L_{(3)} + \lambda_G \sum_{j<k} W_{jk} \cdot ||B_{j,:} - sgn(\rho_{jk})B_{k,:}||_2^2 \tag{9}$$

式（9）鼓励强相关化合物具有相应的系数关系。它是由验证集决定强弱的统计偏好，不是化学定律。应与无网络模型作消融比较；若无收益，可将 λG 设为零。

重要性与 Top-3 的数学表达

$$\max_z \sum_{j \in Jchem} I_{jd} z_{jd'} \quad \sum_{j \in Jchem} z_{jd} = 3, z_{jd} \in \{0,1\} \tag{10}$$

Ijd 取交叉验证中的条件置换重要性，或以分组置换方式处理强共线模块。该选择式在没有额外组合约束时等价于排序取前三。重要性若不显著，应给出候选排名及弱证据标记，不能因要求 Top-3 而夸大确定性。

$$\pi_{jd} = (1/R) \sum_{r=1...R} 1(j \in Top3_d^{(r)}) \quad J(A,B) = |A \cap B| / |A \cup B| \tag{11}$$

采用分风格 bootstrap，报告 Top-3 入选频率 π、不同模型的 Jaccard 系数和作用方向。强相关物质可能相互替代，还应报告其所属模块及模块稳定性。化学合理性通过名称、来源、气味描述、阈值及可用校准单位交叉核对。

2.csv、5.csv、6.csv 和 8.xlsx 已有 GBM／SHAP 是全样本参考。用于严格外部验证时，图和重要性均须在训练折内重算，不能直接将这些参考结果当作独立验证证据。

07 问题三：风格条件生成模型

选择共享结构，控制小样本风格估计

22 种风格样本量不均衡：Blond 为 31 个、Tripel 为 28 个、Pils/Lager 为 11 个、Lambic 为 11 个、Kriek 为 10 个，最少的 Faro 仅 3 个。不宜一开始为每个风格独立训练高容量生成模型。

$$z \mid c \sim N(\mu_c, \Sigma_c), u = Uz + \varepsilon,$$
$$\varepsilon \sim N(0, \Psi), r = \dim(z) \ll p \tag{12}$$

U 为所有风格共享的低维变化结构；μc、Σc 表示风格差异；Ψ 为测量和剩余变化的对角协方差。该式诱导条件分布 u|c~N(mc,Kc)，其中 mc=Uμc，Kc=UΣcU^{T}+Ψ。

$$\min_{\theta} -\sum_{i=1\ldots n} \log p_{\theta}(u_i|c_i)$$
$$+ \alpha\sum_c ||\mu_c||_2^{\,2} + \beta\sum_c ||\Sigma_c - \Sigma_0||_F^{\,2} \tag{13}$$

$$U^{T}U = I_r, \Sigma_c \succeq \varepsilon_0 I_r,$$
$$\Psi = \mathrm{diag}(\psi_1,\ldots,\psi_p), \psi_j \geq \varepsilon_0 > 0 \tag{14}$$

Σ0 是共享潜空间协方差，参数 α、β 控制向总体信息收缩。ε0 为数值稳定下限，与随机误差 ε 区分。潜维度、收缩强度及训练停止条件依据验证表现确定。该模型包含非凸参数估计，应采用多初值并比较收敛结果，不能保证全局最优。

生成与感官画像

生成 给定 Tripel、Kriek、Lambic 等风格，先抽样 z，再生成 u；仅保留满足物理边界、单位规则和统计支持范围的候选样本。

重算派生量 仅对单位和计算规则已核实的综合属性重算；无法核实的总和不得混合任意单位直接相加。

画像 将合格候选输入问题一模型，输出 50 维连续感官画像及相对等级，同时传递预测不确定性。

解释 未经核实逆变换的字段仍称为仪器特征，不能声称已得到真实浓度。生成合理性需要分布检验和独立品评共同支持。

08 跨风格迁移与缺陷不恶化约束

对原始样本 u0 和目标风格 c，在接近目标风格的同时限制改动幅度。所有距离在训练集定义的无量纲特征空间计算。

$$\min_{u'} (u' - u_0)^T D(u' - u_0) + \lambda(u' - m_c)^T K_c^{-1}(u' - m_c) \tag{15}$$

$$u' \in C, \quad (u' - m_c)^T K_c^{-1}(u' - m_c) \le R_c^2 \tag{16}$$

D 为非负对角权重矩阵；λ 控制保留原样本与接近目标风格的权衡；C 汇集已核实的物理边界和数据支持范围。Rc 由训练目标风格的距离分布或验证方案确定，不在缺少依据时指定固定数值。

有可靠阈值的化合物逐项限制

$$[C_j(u')/T_j - 1]_+ \le [C_j(u_0)/T_j - 1]_+, j \in D_{known} \tag{17}$$

[x]+ = max(x,0)。原样本未超阈值时，迁移后仍须在阈值内；原样本已超阈值时，其超阈程度不得增加。由于 Tj>0，式（17）等价于 Cj(u′)≤max{Tj,Cj(u0)}。

缺陷	附件中位阈值	约束口径
DMS	19 μg/L	与校准浓度单位一致后执行式（17）。
Diacetyl	0.09 mg/L	平均阈值为 0.29925 mg/L，须作阈值敏感性分析。
4VG	0.2 mg/L	按赛题列入约束，另说明风格背景。
trans-2-nonenal	附件无阈值	暂采用浓度不增加的保守约束。
Stale hops	无单一对应阈值	预测 stale_hops 不增加，仅作为感官代理约束。

阈值来源：8.xlsx / Sensory thresholds。Stale hops 代理约束含预测误差，不能宣称其化学风险已被严格控制。对输入与目标风格冲突的情况，先检查可行性；若无可行解，应报告冲突或给出可行的折中前沿，不静默放宽缺陷限制。

09 验证方案、适用范围与局限

四组验证必须分开报告

验证对象	方法与输出
预测能力	重复三折外层交叉验证；内层调参。报告逐维与宏平均 MAE、RMSE、秩相关、分风格误差及区间覆盖表现。
关键因素	分风格 bootstrap 入选频率、跨模型 Jaccard、网络阈值敏感性与模块替代性；不以全样本内拟合作为稳定证据。
风格生成	比较留出真样本与生成样本的边缘分布、相关结构、风格识别结果和多样性；独立风格分类器及评估样本均避免泄露。
迁移可行性	逐项回代浓度、可信区域与感官代理约束；列出迁移前后缺陷值、阈值、松弛量及可行性。

敏感性与消融设计

比较有／无网络、有／无 5 项派生指标、不同缺失处理方案、不同潜维度及收缩强度。重点改变网络阈值 τ、缺陷阈值、迁移权重 λ 和可信半径 Rc；先报告参数口径，再比较预测误差、Top-3、生成分布和迁移可行率的变化。

缺失情境可在已观测化学数据上设置多档随机遮蔽和成组缺失，再评估模型退化；人工遮蔽不能证明对真实非随机缺失同样有效。稀有风格误差与生成分布均应附样本量，避免对只有 3 个观测的风格给出过强结论。

适用范围

当前商用啤酒数据覆盖范围内的感官预测、化合物关联解释、候选风格化合物谱筛选，以及带缺陷约束的统计迁移。模型适用于前期分析与实验候选设计。

主要局限

尺度不可识别 没有原始标签时，只能验证标准化连续预测与所定义的相对等级，不能保证原始人工评分一致性。

样本少、维度高 22 种风格分布不均；低维共享结构可降低方差，但可能丢失稀有风格的独特模式。

统计关联不等于因果 配料、工艺和风格等共同因素可能造成化合物共变；改变单一化合物的实际效果需要干预实验。

候选谱不等于配方 缺少酵母、温度、发酵时间等过程变量，不能直接反推可执行酿造工艺；最终合理性需实验及品评确认。

10 后续实施接口与资料来源

可交给代码阶段的任务清单

任务	输入与方法	输出与校验
数据字典	1／4／7.csv、3／8.xlsx；按 beer 对齐，核对变换、单位和缺失机制。	字段映射与差异清单；确认样本唯一、标签对应、原始文件未改。
问题一	化学特征→标准化感官标签；稳健稀疏回归与比较模型。	连续预测、相对等级、误差与区间；训练折内插补、缩放和分级。
问题二	训练集共变图＋预测模型；条件／模块置换与 bootstrap。	每维 Top-3、入选频率、模块及化学证据；排除综合量冒充单物质。
问题三	共享潜因子＋风格参数收缩；条件抽样与约束优化。	候选谱、感官画像、迁移前后对照；逐项验算约束与不可行情形。
综合验收	独立留出、消融、缺失压力测试与关键阈值扰动。	可复现的参数与数值记录；不把预设方案写成已完成结果。

资料索引（均位于原始工作目录）

[S1] 2026年MathorCup大数据挑战赛-赛道A初赛.pdf：研究背景、三问及附件说明。
[S2] 数据说明.txt：附件用途说明。
[S3] 1.csv：化学主表；[S4] 2.csv：化学相关矩阵。
[S5] 3.xlsx：beer_1 – beer_12、summary，评分体系及空白公式核查。
[S6] 4.csv：标准化感官主标签；[S7] 5.csv：感官相关矩阵。
[S8] 6.csv：化学—感官交叉相关；7.csv：数值描述符辅助表。
[S9] 8.xlsx：Sensory thresholds、Sensory names、Calibrated chemical dataset 等参考表。

本轮形成的结论与尚待确定事项

已确定：样本连接主键、数据实际维度、相关矩阵类型、部分 log10 变换、评分尺度限制、三问模型骨架及验证路径。已确认采用核心 30 项＋扩展 20 项，乙醛感受单列。

尚待实施时估计：模型参数、潜维度、图阈值、相对分级阈值、预测区间及迁移可信区域。尚待核实：未校准特征的量纲与变换、校准表少量差异记录、缺失缺陷阈值和 Stale hops 的代理有效性。

当前交付：一份可直接阅读的建模分析稿。未产生正式预测分数、真实 Top-3 清单、已验证生成样本或酿造配方；这些结果必须在后续实验与验证完成后给出。